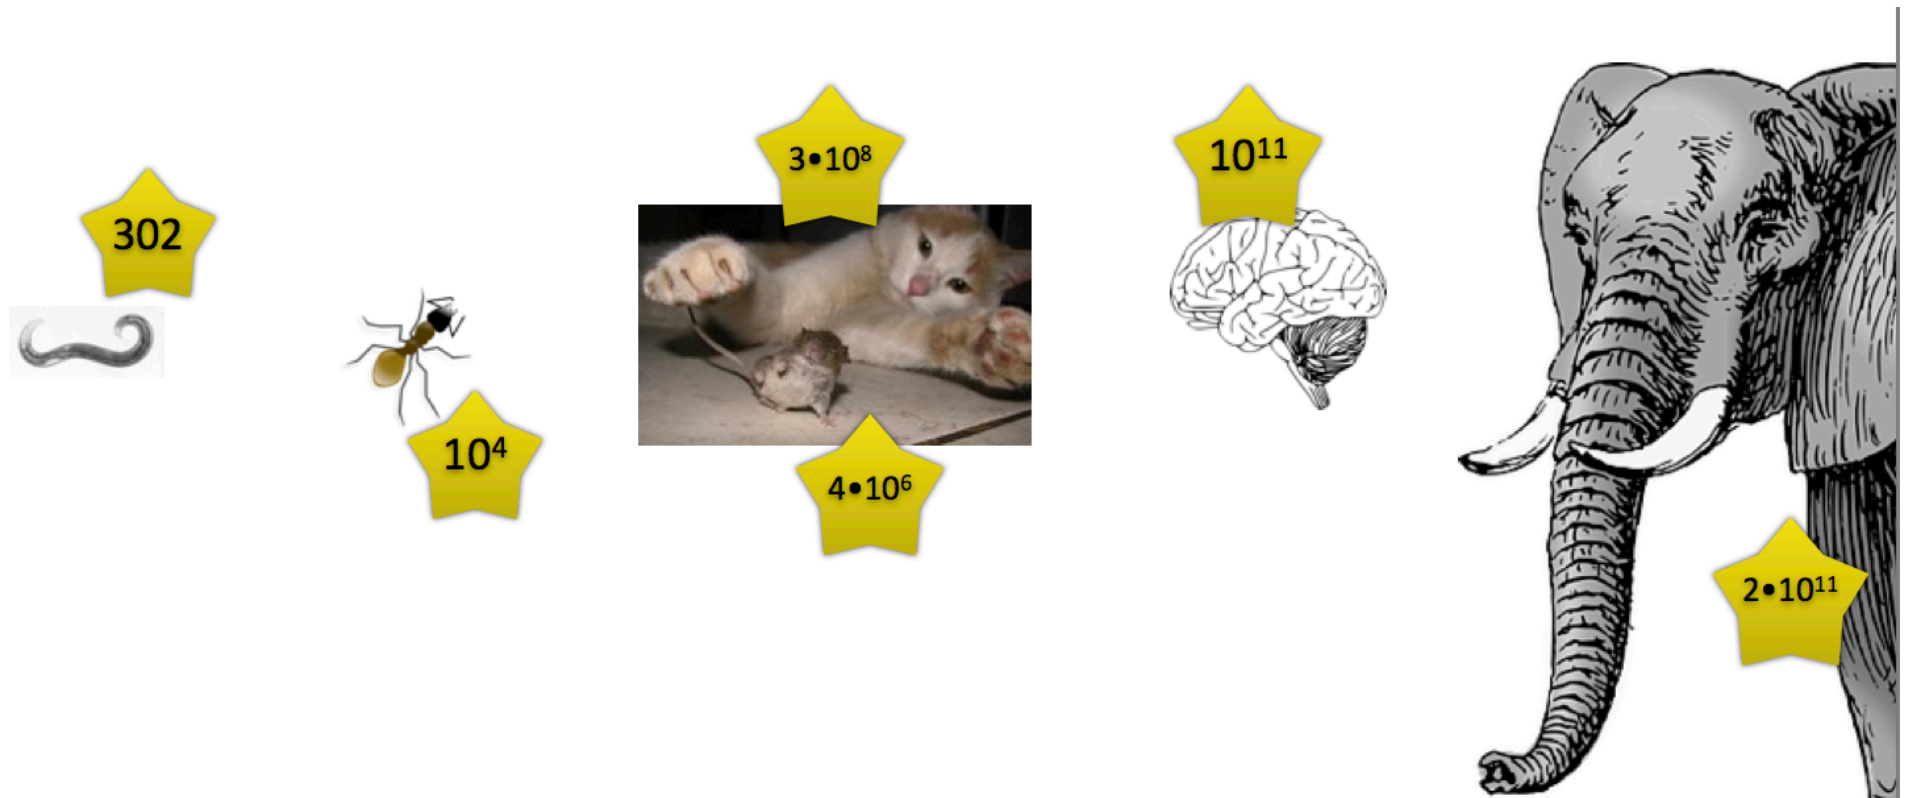


# Redes Neurais Artificiais

Computação Natural

Gisele L. Pappa


# Como aprendemos?



# Inspiração...

	Brain	Computer
No. of processing units	$\approx 10^{11}$	$\approx 10^9$
Type of processing units	Neurons	Transistors
Type of calculation	massively parallel	usually serial
Data storage	associative	address-based
Switching time	$\approx 10^{-3}s$	$\approx 10^{-9}s$
Possible switching operations	$\approx 10^{13} \frac{1}{s}$	$\approx 10^{18} \frac{1}{s}$
Actual switching operations	$\approx 10^{12} \frac{1}{s}$	$\approx 10^{10} \frac{1}{s}$

**Table 1.1:** The (flawed) comparison between brain and computer at a glance. **Inspired by:** [Zel94]



# Definição

“Redes Neurais Artificiais são dispositivos de computação paralela que consistem de muitos processadores interconectados. Esses processadores são simples... Cada processador está ciente apenas dos sinais que manda para e recebe de outros processadores periodicamente”  
(Callan, “The Essence of Neural Networks”)

# De onde veio a inspiração?

- O processamento que ocorre no cérebro é altamente **paralelo**
  - Paralelismo é uma das características de arquitetura mais difíceis de serem computacionalmente bem exploradas
  - Entender como o cérebro “computa” pode nos ajudar

# De onde veio a inspiração?


- Os “processadores” do cérebro (neurônios) são muito lentos se comparados com dispositivos eletrônicos.
  - Mesmo assim, o sistema nervoso pode produzir resultados para problemas difíceis muito mais rápido que um computador
- A ideia é produzir neurônios artificiais que usem a mesma arquitetura de processamento do cérebro, mas que sejam mais rápidos que os neurônios naturais

# O Sistema Nervoso (SN)

- O sistema nervoso traz informações para o organismo sobre o ambiente ao seu redor através de **entradas** sensoriais, **processa** a informação de entrada, **compara** com experiências anteriores, e **transforma** essas entradas em **ações ou memória**




# Níveis de Organização do SN



# Neurônios

- Processamento de sinal
- Dependendo das condições do ambiente, neurônios geram sinais (potenciais elétricos) que são utilizados para transmitir “informações” a outros neurônios aos quais ele está conectado.

# Estrutura de um Neurônio



# Redes, Camadas e Mapas

- Neurônios podem ter conexões “para frente” (*forward*) ou “por realimentação” (*feedback*) com outros neurônios
- Essas interconexões dão origem às **redes neurais** (neuronaís)
- Representação da informação é feita de maneira distribuída, e seu processamento é paralelo

# Redes, Camadas e Mapas

- Em algumas regiões do cérebro, os neurônios estão organizados em **camadas**
  - Camada de entrada, camadas escondidas e camada de saída
- Em outras regiões (sistemas sensorial e motor), a organização dos neurônios é como uma **mapa topográfico**
  - Ex: neurônios de áreas visuais são adjacentes a neurônios do campo de recepção da visão, e juntos eles formam o mapa da retina

# Aprendizagem

- O SN está continuamente se modificando e se adaptando
- Aprendizagem global é resultado de mudanças locais nos neurônios
  - Sinapses
- 2 tipos de mecanismo de aprendizagem e memória:
  - Potenciação de longa duração
  - Depressão de longa duração

# Aprendizagem

- Sinapses e neurotransmissores
  - Quando o impulso de um neurônio chega ao axônio, causa a liberação de neurotransmissores (substâncias químicas), que passam para os receptores dos dendritos de um outro neurônio
- A chegada desses neurotransmissores causa mudanças no potencial elétrico de um dendrito, e eles são propagados para o corpo da célula
- No corpo da célula, esses **sinais** (neurotransmissores) são **integrados (somados)** e o potencial de membrana gerado determinará se o neurônio vai excitar os outros na rede ou não

# Memória

- Também é produto da adaptação das conexões das sinapses
- 3 tipos de memória
  - Curto prazo
  - Médio prazo
  - Longo prazo
    - Depende de mudanças estruturais das sinapses



# Redes Neurais Artificiais

- Processamento da informação ocorre nos neurônios
- Neurônios recebem e enviam estímulos do/para outros neurônios e de/para o ambiente
- Neurônios podem ser conectados formando redes neurais


# Redes Neurais Artificiais

- Informação é transmitida através de sinapses
- A eficiência de uma sinapse é representada por um peso, que corresponde a informação armazenada no neurônio
- Conhecimento é adquirido através de aprendizagem
  - Adaptação dos pesos das sinapses de acordo com a informação do ambiente

# Redes Neurais Artificiais

- Caracterizadas por 3 elementos:
  - Conjunto de neurônios artificiais
  - Um padrão de conexão entre os neurônios
    - Arquitetura ou estrutura da rede
  - Método que determina o valor dos pesos
    - Algoritmo de treinamento ou aprendizagem

# Redes Neurais Artificiais



# Neurônios Artificiais


- Alto nível de abstração a relação a neurônios biológicos
- 2 modelos de neurônios
  - McCulloch-Pitts (1943) - função lógica
  - Modelo connexionista genérico

# Neurônio de McCulloch-Pitts (1943)

- Neurônio de 2 estados
  - Comportamento de um neurônio é um processo binário
- Cada neurônio tem um limiar fixo  $l$ 
  - função de ativação
- Os valores dos pesos da entrada são sempre iguais

# Neurônio de McCulloch-Pitts (1943)

- Neurônio de 2 estados
- Cada neurônio tem um limiar fixo  $l$
- Os valores dos pesos da entrada são sempre iguais




# Neurônio de McCulloch-Pitts (1943)

- Considere um neurônio com 2 entradas binárias  $x_1$  e  $x_2$
- O que acontece quando o limiar:

$$l = 1$$

$$l = 2$$




a	b	a OR b
0	0	0
0	1	1
1	0	1
1	1	1

a	b	a AND b
0	0	0
0	1	0
1	0	0
1	1	1



# Modelo Conexionista Genérico



$$y_k = f(u_k) = f\left(\sum_{j=1}^m w_{kj} x_j + b_k\right)$$

Or, assuming  $w_{k0} = b_k$

$$y_k = f(u_k) = f\left(\sum_{j=0}^m w_{kj} x_j\right)$$

- Bias do neurônio
  - Aumenta ou diminui a entrada da rede para a função de ativação
  - Ele substitui o limiar

# Diferenças entre os 2 neurônios

- McCulloch-Pitts

$$y = f(u) = \begin{cases} 1 & \text{se } u \geq l \\ 0 & \text{caso contrário} \end{cases}$$



onde  $u = x_1 + x_2$

- Modelo Conexionista Genérico



$$y = f(u) = \begin{cases} 1 & \text{se } u \geq 0 \\ 0 & \text{caso contrário} \end{cases}$$

onde  $u = w_1 x_1 + w_2 x_2 + b_k$

# Qual o papel do peso e do *bias*?




# Qual o papel do peso e do *bias*?




# Modelo Conexionista Genérico


- Funções de ativação
  - Introduzem não linearidade




(a)



(b)



(c)



(d)

- (a) Linear
- (b) Limiar
- (c) Sigmoid (logística)
- (d) Gaussiana

- A sigmoide é a função mais utilizada na literatura
- A Gaussiana é muito utilizada em redes RBF

# Arquiteturas de Rede

- Interação entre agentes
  - Leva a um comportamento emergente
- Sistemas naturais
  - Comportamento de um neurônio pode afetar o comportamento de outros
  - Individualmente, o comportamento de um neurônio não leva a nenhuma conclusão
  - Não se conhece muito sobre como os neurônios estão conectados no cérebro (temos informações sobre áreas específicas)

# Arquiteturas de Rede

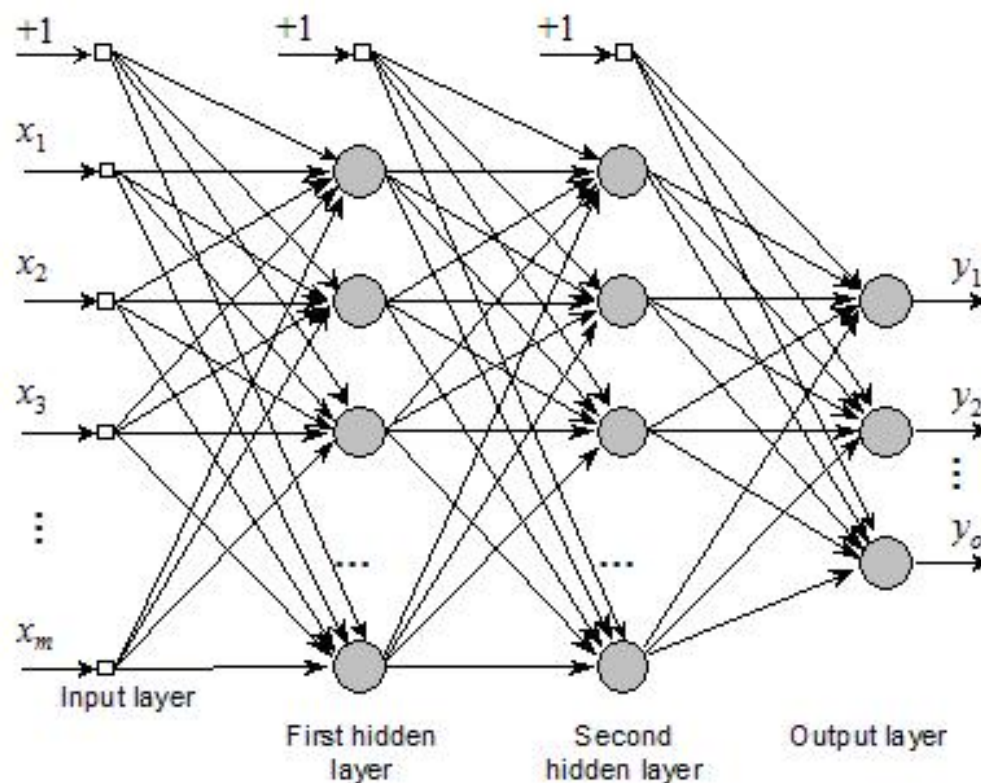

- Existe uma arquitetura padrão para redes
  - Uma camada de entrada
  - Uma ou mais camadas intermediárias (oculta)
  - Uma camada de saída
- A maneira como os neurônios estão conectados é fortemente dependente do algoritmo de aprendizagem utilizado para treinar a rede

# Arquiteturas de Rede

- Existem 3 tipos principais de arquitetura:
  - Redes *feedforward* de uma camada
  - Redes *feedforward* de multi-camadas
  - Redes recorrentes



# Redes *feedforward*




- Propagação do sinal ocorre sempre da entrada para saída

# Redes *feedforward*

- Redes de uma camada
  - Normalmente as funções de entrada são lineares
    - Simplesmente propagam sinal para próxima camada
- Redes multi-camada
  - Insere-se funções não lineares na camada oculta
  - O algoritmo de treinamento para este tipo de rede envolve a retropropagação (*backpropagation*) do erro entre a saída da rede e uma saída desejada conhecida.
- O que acontece se as funções de ativação das unidades intermediárias forem lineares?

# Redes Recorrentes

- Possuem pelo menos um laço realimentando a saída de neurônios para outros neurônios da rede.



# O que uma rede faz?

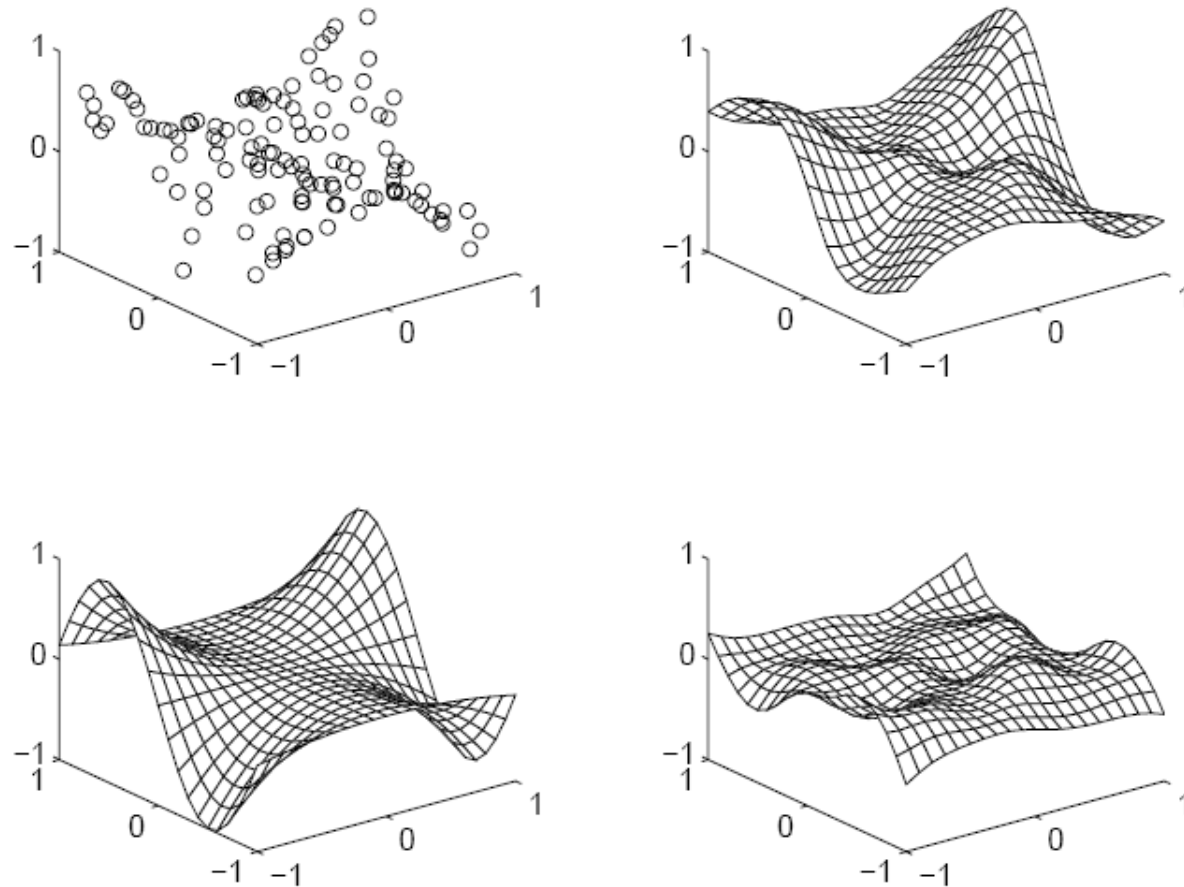

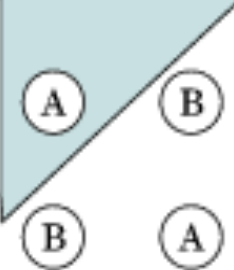
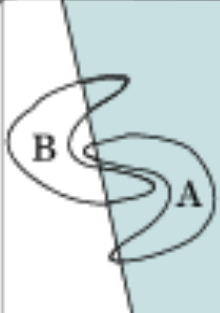

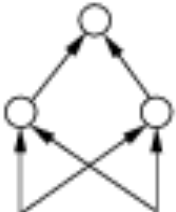
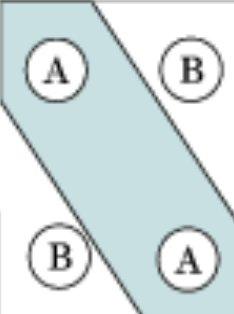
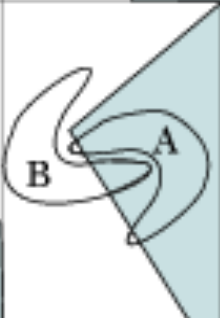


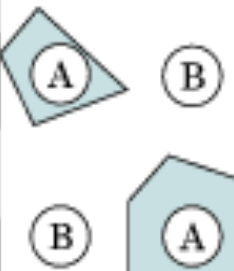




Figure 4.3: Example of function approximation with a feedforward network. Top left: The original learning samples; Top right: The approximation with the network; Bottom left: The function which generated the learning samples; Bottom right: The error in the approximation.

# O que uma camada a mais faz?

Structure	Types of decision regions	Exclusive OR problem	Classes with meshed regions	Most general region shapes	
Single-layer 	Half Plane (Bounded by hyperplane)				(a)
Two-layer 	Convex (Open or closed regions)				(b)
Three-layer 	Arbitrary (Complexity limited by number of neurons)				(c)

# Aprendizagem

- **Aprendizagem** (treinamento) corresponde ao processo de ajuste dos parâmetros livres da rede através de padrões (ou dados) de entrada ou de treinamento:

estímulo

adaptação

novο comportamento da rede



# Aprendizagem

- Seja  $w(t)$  um peso sináptico de um dado neurônio, no instante de tempo  $t$ . O ajuste  $\Delta w(t)$  é aplicado ao peso sináptico  $w(t)$  no instante  $t$ , gerando o valor corrigido  $w(t+1)$ , na forma:

$$w(t+1) = w(t) + \Delta w(t)$$

- Várias maneira de obter  $\Delta w(t)$ :
  - regra de Hebb, regra Delta, algoritmo de *backpropagation*, estratégias de competição, máquina de Boltzmann

# Regra de Hebb

- As mudanças nos pesos das conexões são dadas pelo produto da atividade pre e pós sináptica, ou seja:

$$\mathbf{w}(t+1) = \mathbf{w}(t) + \alpha y_i x_i$$

$\alpha$  é a taxa de aprendizagem

x/y correspondem a entrada/saída do neurônio i

- Se  $\alpha$  é pequeno, rede aprende muito devagar
- Se  $\alpha$  é alto, os pesos acabam divergindo



# Aprendizagem

## Supervisionado

- Existe uma resposta de saída esperada para rede


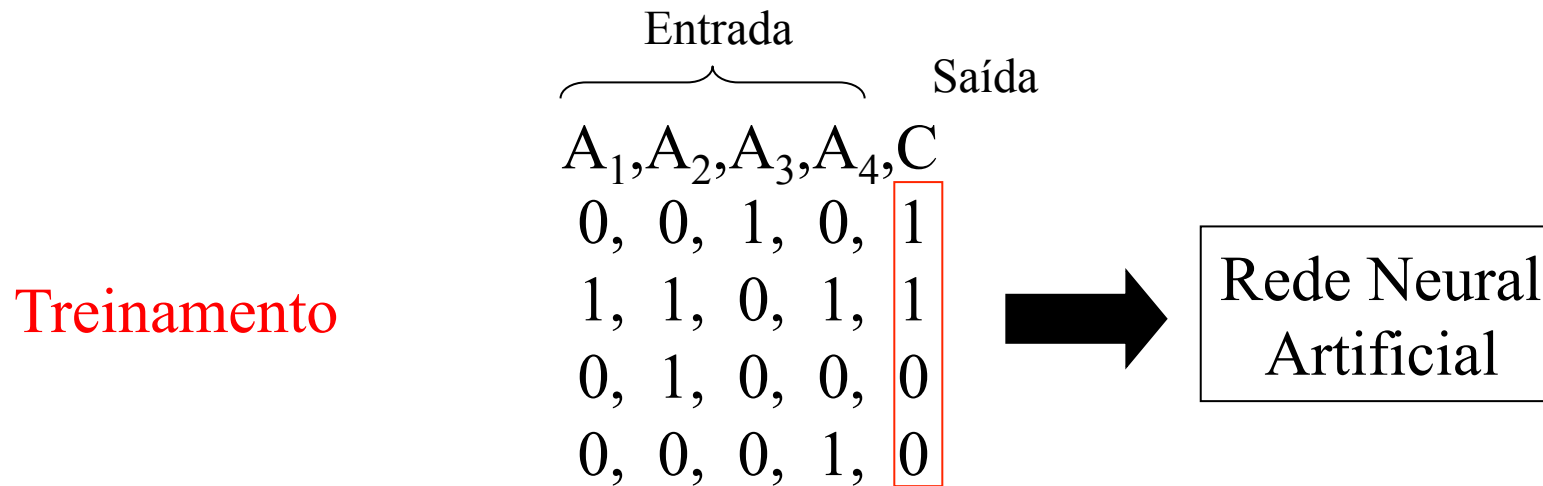
- Não-supervisionado

- Resposta esperada é desconhecida

- Por reforço


- Existe apenas um valor escalar que indica a qualidade do desempenho da RNA.

# Aprendizagem Supervisionada



- Capacidade de Generalização da rede

# Aprendizagem Supervisionada



# Aprendizagem não-supervisionada

- Saída esperada não é conhecida
  - Não é possível propagar o erro para atualizar os pesos da rede
- A rede se adapta a regularidades estatísticas nos dados de entrada
  - Cria representações internas que codificam as características dos dados de entrada, tornando-se capaz de identificar a quais classes novos padrões pertencem.

# Aprendizagem não-supervisionada

- Utiliza algoritmos de aprendizagem competitiva
  - Os neurônios de saída da rede **competem** entre si para se tornarem ativos, com um único neurônio sendo o vencedor da competição
  - Neurônios individuais aprendem a se especializar a conjuntos (grupos ou clusters) de padrões similares. Eles se tornam detectores ou extratores de características para diferentes classes dos dados de entrada

# Aprendizagem não-supervisionada

- Para que um neurônio  $i$  seja o vencedor
  - A distância entre o vetor de pesos  $\mathbf{w}_i$  deste neurônio e um determinado padrão de entrada  $\mathbf{x}$  deve ser a menor dentre todos os outros neurônios da rede, dada uma métrica de distância  $\|\cdot\|$  (geralmente utiliza-se a distância Euclidiana).

# Aprendizagem não-supervisionada

- Adaptação dos pesos

$$\Delta\omega = \begin{cases} 0 & \text{se perde a competição} \\ \alpha(\mathbf{x}-\mathbf{w}_i) & \text{se ganha a competição} \end{cases}$$

onde  $\alpha$  indica o tamanho do passo a ser dado na direção de  $\mathbf{x}$  . O parâmetro  $\alpha$  é conhecido como taxa de aprendizagem.

# Aprendizagem por Reforço

- Durante o processo de aprendizagem, a rede “tenta” algumas ações (saídas) e recebe um sinal de reforço (estímulo) do ambiente que permite avaliar a qualidade de sua ação.
- O sistema em aprendizagem seletivamente retém as ações que levam a uma maximização dos sinais de reforço.



# Aprendizagem por Reforço

- A cada iteração  $t$ , o sistema em aprendizagem recebe uma entrada  $\mathbf{x}(t)$ , fornece uma saída  $y(t)$ , e no próximo passo recebe um escalar de reforço  $r(t+1)$  e um novo estado do ambiente  $\mathbf{x}(t+1)$ .
- Um dos conceitos básicos por trás da aprendizagem por reforço é a busca por tentativa e erro

# Tipos de Redes Neurais

- Supervisionadas
  - Backpropagation
  - RBF (Radial Basis Function)
  - Redes de memória associativa
    - Boltzmann
    - Hopfield
    - Ensina a rede a aprender associações entre os padrões de entrada e saída

# Tipos de Redes Neurais

- Não-supervisionadas
  - ART e variações
    - Resolve um dos maiores problemas de RNA: incapacidade de aprender material novo preservando o material antigo
    - Trabalha em dois estados:
      - De aprendizagem
      - De estabilidade
    - Auto-organizável
  - SOM (Self-Organization Maps) ou Redes de Kohonen

# Velhas histórias sobre redes neurais...

- Exército americano usou redes neurais para identificar tanques inimigos escondidos entre árvores



# Reconhecimento de Tanques em Imagens

- Idéia: acoplar uma câmera a cada tanque, que scaneava o ambiente continuamente. Quando algo suspeito era encontrado, avisar os soldados. Usar uma rede neural para realizar tal tarefa.

# Reconhecimento de Tanques em Imagens

- Dados de entrada
  - 100 fotos de tanques escondidos atrás de árvores e 100 fotos de árvores.
  - Metade das fotos de cada grupo utilizado para treinar uma rede
- Teste – acerto de 100%
- Teste independente: outras 100 fotos de tanques... As respostas da rede foram aleatórias.. Por que?

# Reconhecimento de Tanques em Imagens

- Todas as fotos dos tanques haviam sido tiradas em um dia nublado, e todas as fotos das árvores em um dia ensolarado
- A rede aprendeu a distinguir os dois grupos utilizando a cor do céu!
- Moral da história: em certas aplicações, redes podem não ser a melhor opção, dado que o modelo gerado dificilmente pode ser compreendido

# Leitura Recomendada

- <ftp://ftp.sas.com/pub/neural/FAQ.html#questions>